

Projekt Seri Kohore

Sami Hoxha

2025-01-10

1. Hyrje

```
library(readxl)
data <- read_excel("Dataset3.xlsx")
head(data)
```

```
## # A tibble: 6 x 4
##   Viti ProdhimiDritherave PlehraKimike   CO2
##   <dbl>          <dbl>          <dbl> <dbl>
## 1  1961          293932          6650  1.29
## 2  1962          313508          4110  1.35
## 3  1963          293449          4040  1.10
## 4  1964          350144          3990  1.03
## 5  1965          335293          3830  1.08
## 6  1966          433094          5560  1.23
```

Qëllimi i Projektit: Ky projekt synon të analizojë ndryshimet dhe trendet e prodhimit të drithërave në lidhje me përdorimin e plehrave kimikë dhe emëtimet e CO2 në një periudhë afatgjatë, duke përdorur analiza të serive kohore.

Pyetjet Kërkimore:

- Si ka ndryshuar prodhimi i drithërave gjatë periudhës së studimit?
- A ka një ndikim të drejtpërdrejtë përdorimi i plehrave kimikë dhe emetimet e CO2 në prodhimin e drithërave?
- Si mund të parashikohen ndryshimet e ardhshme në prodhimin e drithërave?

2. Përgatitja e të Dhënave

- **Përshkrimi i Të Dhënave:**

Variablat: - Viti: Viti i të dhënave. - ProdhimiDritherave: Prodhimi i drithërave (kg për hektar). - PlehraKimike: Përdorimi i plehrave kimikë (kg për hektar). - CO2: Emetimet e CO2 .

- **Burimi i të Dhënave:**

Këto të dhëna janë të besueshme dhe janë burim nga “Our World in Data”, të cilat përfaqësojnë një periudhë 59-vjeçare (1961 - 2020), duke lejuar analizën e tendencave afatgjata dhe të ndikimeve të ndërsjella midis variablove të përzgjedhur.

- Konvertimi i datave në format kohor:

```
data$Date <- as.Date(paste0(data$Viti, "-01-01"))
```

- Kontrolli për vlera që mungojnë:

```
missing_values <- sum(is.na(data))  
cat("Numri i vlerave që mungojnë në dataset është:", missing_values, "\n")
```

```
## Numri i vlerave që mungojnë në dataset është: 0
```


Meqë numri i vlerave të munguara është 0, do të thotë që dataset-i është i plotë dhe nuk kemi nevojë të merremi me trajtimin e mungesave në të dhëna. Tani mund të kalojmë direkt në analizat e tjera.

3. Analiza Eksploruese e të Dhënave

- 3.1 Vizualizimet e serive : 3.1.1) Vizualizimi i serisë kohore për Prodhimin e Drithërave

```
library(ggplot2)  
ggplot(data, aes(x = Date, y = ProdhimiDritherave)) +  
  geom_line(color = "blue", size = 1) +  
  ggtitle("Prodhimi i Drithërave nga Viti 1961 në 2020") +  
  scale_x_date(date_labels = "%Y", date_breaks = "4 years") +  
  labs(x = "Viti", y = "Prodhimi i Drithërave") +  
  theme_minimal() +  
  theme(  
    axis.text.x = element_text(angle = 45, hjust = 1),  
    plot.title = element_text(hjust = 0.5, size = 14, face = "bold")  
  )
```

```
## Warning: Using 'size' aesthetic for lines was deprecated in ggplot2 3.4.0.  
## i Please use 'linewidth' instead.  
## This warning is displayed once every 8 hours.  
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was  
## generated.
```




Grafiku i serisë kohore tregon një trend rritës afatgjatë, me disa luhajtje gjatë viteve 1960-1980. Pas vitit 1990, rritja bëhet më e qëndrueshme.

3.1.2) Vizualizimi i serisë kohore për CO2

```
ggplot(data, aes(x = Date, y = CO2)) +
  geom_line(color = "green", size = 1) +
  ggtitle("Emëtimi i CO2 nga Viti 1961 në 2020") +
  scale_x_date(date_labels = "%Y", date_breaks = "4 years") +
  labs(x = "Viti", y = "CO2 (metric tonnes)") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    plot.title = element_text(hjust = 0.5, size = 14, face = "bold")
  )
```

Emëtimi i CO2 nga Viti 1961 në 2020




CO2 ka një trend rritës të qëndrueshëm, që mund të lidhet me rritjen e industrializimit dhe aktivitetet intensive bujqësore. Pas vitit 1995, rritja bëhet më e qëndrueshme.

3.1.3) Vizualizimi i serisë kohore për Plehrat Kimike

```
ggplot(data, aes(x = Date, y = PlehraKimike)) +
  geom_line(color = "red", size = 1) +
  ggtitle("Plehrat Kimike nga Viti 1961 në 2020") +
  scale_x_date(date_labels = "%Y", date_breaks = "4 years") +
  labs(x = "Viti", y = "Plehra Kimike (tonë)") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    plot.title = element_text(hjust = 0.5, size = 14, face = "bold")
  )
```

Plehrat Kimike nga Viti 1961 në 2020



Grafiku për plehrat kimike ka një rritje të fortë lineare nga vitet 1961 deri në 2020, që tregon një intensifikim të përdorimit të plehrave kimike për të përmirësuar produktivitetin bujqësor. Pas vitit 1990, rritja bëhet më e qëndrueshme.

• 3.2 Statistika përmbledhëse:

```
summary(data)
```

```
##      Viti      ProdhimiDritherave  PlehraKimike      CO2
##  Min.   :1961   Min.    : 293449   Min.    : 3830   Min.    :0.4742
## 1st Qu.:1976   1st Qu.: 503410   1st Qu.: 21522   1st Qu.:1.2495
## Median :1990   Median : 645713   Median : 49485   Median :1.6217
## Mean   :1990   Mean   : 660907   Mean   : 50074   Mean   :1.5921
## 3rd Qu.:2005   3rd Qu.: 741402   3rd Qu.: 62268   3rd Qu.:1.8938
## Max.   :2020   Max.   :1067000   Max.   :113010   Max.   :2.7379
##      Date
##  Min.   :1961-01-01
## 1st Qu.:1975-10-01
## Median :1990-07-02
## Mean   :1990-07-02
## 3rd Qu.:2005-04-02
## Max.   :2020-01-01
```

3.2.1) Vlera mesatare për seritë

```
mesataret <- sapply(data[, c("ProdhimiDritherave", "PlehraKimike", "C02")], mean)
print(mesataret)
```

```
## ProdhimiDritherave      PlehraKimike      C02
##      6.609074e+05      5.007350e+04      1.592133e+00
```

3.2.2) Devijimi standart për seritë

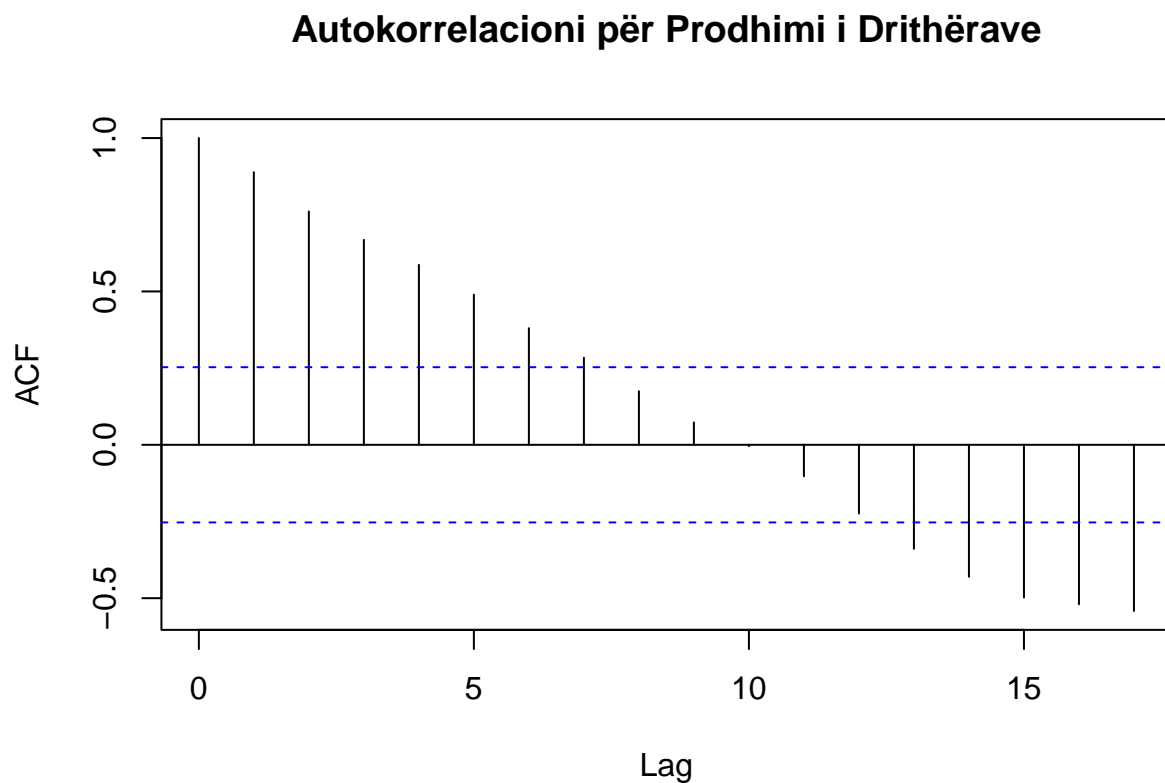
```
devijimistandart <- sapply(data[, c("ProdhimiDritherave", "PlehraKimike", "C02")], sd)
print(devijimistandart)
```

```
## ProdhimiDritherave      PlehraKimike      C02
##      2.095177e+05      3.314175e+04      5.783174e-01
```

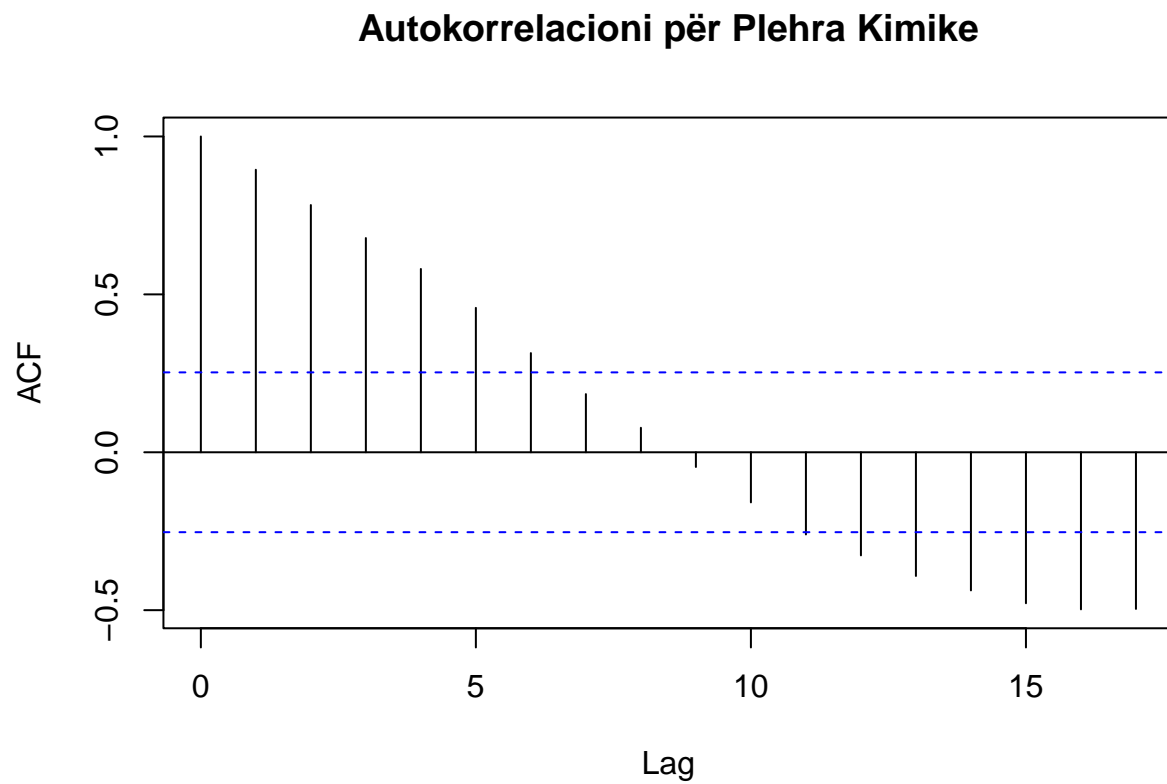
Variablat tregojnë shpërndarje të gjerë, sidomos për prodhimin e drithërave dhe plehrave kimike.

- **3.3 Autokorrelacionet:**

```
# Autokorrelacioni për Prodhimi i Drithërave
acf(data$ProdhimiDritherave, main = "Autokorrelacioni për Prodhimi i Drithërave")
```




```
# Autokorrelacioni për Plehra Kimike  
acf(data$PlehraKimike, main = "Autokorrelacioni për Plehra Kimike")
```



```
# Autokorrelacioni për CO2  
acf(data$CO2, main = "Autokorrelacioni për CO2")
```

Autokorrelacioni për CO2



- Grafiku ACF për Prodhimin e Drithërave tregon:
 - Vlera të larta të autokorrelacionit për laget e para, duke sugjeruar një lidhje të fortë mes vlerave të njëpasnjëshme të serisë kohore.
 - Gradualisht, autokorrelacionet zvogëlohen, por disa vlera janë ende mbi kufirin dhe për laget e mëdha, që sugjeron prani të një trendi afatgjatë.

Interpretimi:

- Këto rezultate janë tipike për seri kohore jo stacionare, siç është konfirmuar edhe nga testi i stacionaritetit (ADF).
- Trendet afatgjata dhe struktura e lidhur me kohën sugjerojnë nevojën për diferencim për të eliminuar ndikimin e trendit.

- Grafiku ACF për Plehrat Kimike tregon:
 - Një model të ngjashëm me prodhimin e drithërave, ku autokorrelacionet fillestare janë shumë të larta dhe pastaj gradualisht zvogëlohen.
 - Kjo tregon se plehrat kimike kanë një strukturë të fortë trendi, që ndikon te vlerat në periudha të njëpasnjëshme.

Interpretimi:

- Këto rezultate tregojnë që përdorimi i plehrave kimike ndjek një model të qëndrueshëm të rritjes afatgjatë.
- Diferencimi ose përdorimi i modeleve të trendit si Holt-Winters është i përshtatshëm për modelimin e kësaj serie.

- Grafiku ACF për Emëtimet e CO2:
 - Tregon gjithashtu autokorrelacione të larta për laget fillestare, por me një rënie më të shpejtë krahasuar me dy seritë e tjera.
 - Kjo sugjeron një trend më të moderuar afatgjatë në krahasim me prodhimin e drithërave dhe plehrat kimike.

Interpretimi:

- Emetimet e CO2 kanë një lidhje më të dobët afatgjatë, por ende ndjekin një strukturë trendi.
- Ky variabël është më pak i lidhur me ciklet kohore të ngjashme me plehrat kimike ose prodhimin e drithërave.

- 3.4 Matrica e Korrelacionit:

```
library(corrplot)
```

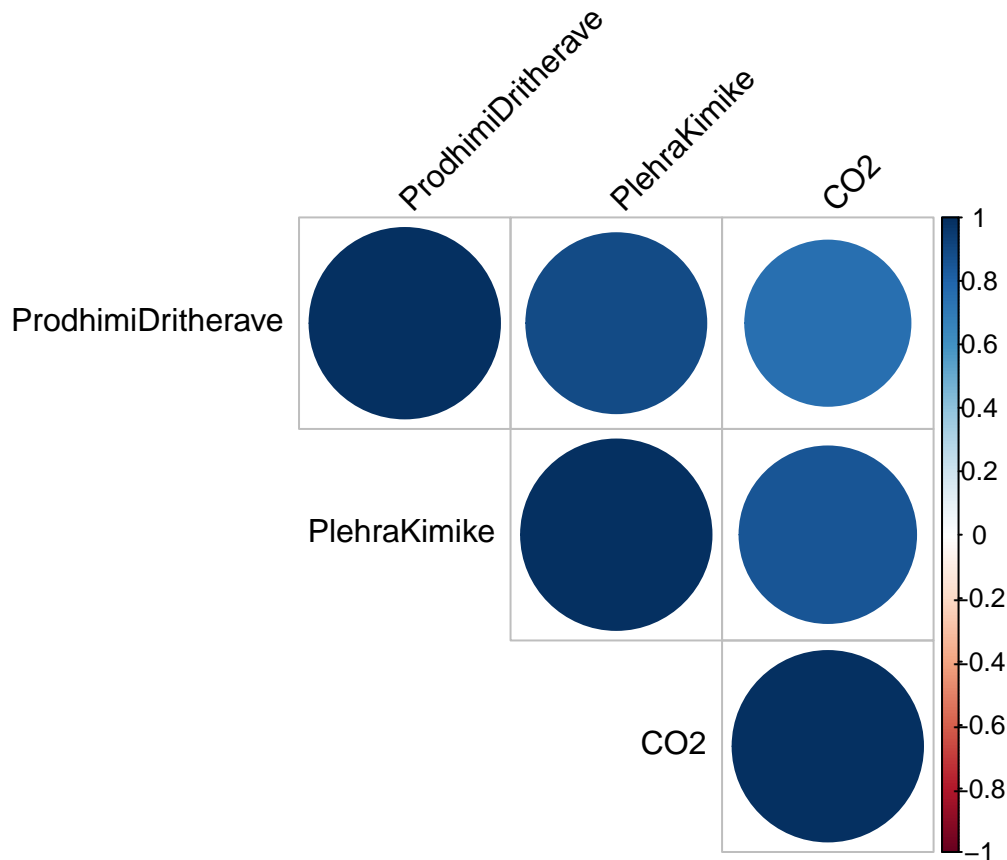
```
## corrplot 0.95 loaded
```

```
cor_matrix <- cor(data[, c("ProdhimiDritherave", "PlehraKimike", "CO2")])
print(cor_matrix)
```

```
##               ProdhimiDritherave PlehraKimike      CO2
## ProdhimiDritherave      1.0000000    0.8933734 0.7527944
## PlehraKimike            0.8933734    1.0000000 0.8596405
## CO2                    0.7527944    0.8596405 1.0000000
```

```
# Vizualizimi i matricës së korrelacionit
```

```
corrplot(cor_matrix, method = "circle", type = "upper", tl.col = "black", tl.srt = 45)
```



Korrelacion i lartë pozitiv midis plehrave kimike dhe prodhimit të drithërave ($r = 0.89$). Korrelacion i moderuar midis CO2 dhe prodhimit të drithërave ($r = 0.75$).

- 3.5 Paraqitja e të dhënave si objekt i serive kohore:

```
# Krijimi i serisë kohore
ts_prodhimi_dritherave <- ts(data$ProdhimiDritherave, start = c(1961), frequency = 1)
ts_plhera_kimike <- ts(data$PlehraKimike, start = c(1961), frequency = 1)
ts_CO2 <- ts(data$CO2, start = c(1961), frequency = 1)
```

- **3.6 Kontrolli i Stacionaritetit për serinë e Prodhimit të Drithërave:** ADF test

```
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo
```

```
adf.test(ts_prodhimi_dritherave) #p-value (0.5701) me e madhe se 0.05 (Seria jo stacionare)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: ts_prodhimi_dritherave
## Dickey-Fuller = -2.0115, Lag order = 3, p-value = 0.5701
## alternative hypothesis: stationary
```

Seria e prodhimit të drithërave është jo stacionare siç e pamë dhe nga ndërtimi i autokorrelacioneve, prandaj do duhet të bejmë diferencimin e serisë për të eliminuar trendin.

- **3.7 Diferencimi i serisë të Prodhimit të Drithërave dhe kontrolli i stacionaritetit:**

```
ts_diff <- diff(ts_prodhimi_dritherave) # Për stacionarizim
adf.test(ts_diff)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: ts_diff
## Dickey-Fuller = -3.8399, Lag order = 3, p-value = 0.02277
## alternative hypothesis: stationary
```

```
kpss.test(ts_diff)
```

```
## Warning in kpss.test(ts_diff): p-value greater than printed p-value
```

```
##
## KPSS Test for Level Stationarity
##
## data: ts_diff
## KPSS Level = 0.20209, Truncation lag parameter = 3, p-value = 0.1
```


Pas diferencimit, seria bëhet stacionare ($p < 0.05$), duke sugjeruar një trend rritës që duhet larguar për modelim të suksesshëm.

- **3.8 Modeli i Regresit Linear për prodhimin e drithërave:**

```
library(forecast)
model_prod_dritherave <- lm(ProdhimiDritherave ~ PlehraKimike , data = data)
summary(model_prod_dritherave)
```

```
##
## Call:
## lm(formula = ProdhimiDritherave ~ PlehraKimike, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -191590  -65348    8489   72648  190053
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.781e+05  2.234e+04   16.93  <2e-16 ***
## PlehraKimike  5.648e+00  3.730e-01   15.14  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 94950 on 58 degrees of freedom
## Multiple R-squared:  0.7981, Adjusted R-squared:  0.7946
## F-statistic: 229.3 on 1 and 58 DF,  p-value: < 2.2e-16
```

```
# Vizualizimi i regresionit
ggplot(data, aes(x = PlehraKimike, y = ProdhimiDritherave)) +
  geom_point() +
  geom_smooth(method = "lm", formula = y ~ x , se = TRUE, color = "blue") +
  labs(title = "Ndikimi i Plehrave Kimike në Prodhimin e Drithërave",
       x = "Plehra Kimike",
       y = "Prodhimi i Drithërave") +
  theme_minimal()
```



```
# Saktësia
accuracy(model_prod_dritherave)
```

```
##               ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 1.1399e-11 93351.64 77313.57 -2.613464 13.65529 0.4670403
```

Modeli midis prodhimit të drithërave dhe plehrave kimike ka një $R\text{-squared} = 0.79$, duke treguar se 79% e variacionit në prodhim shpjegohet nga plehrat kimike. Prandaj ky model është i mirë për të parashikuar prodhimin e drithërave duke përdorur ndryshoren e plehrave kimike.

Rezultatet: - Plehrat kimike kanë ndikim të rëndësishëm pozitiv ($p < 0.001$). - Ky model është i thjeshtë, por i fuqishëm për interpretim.


4. Ndërtimi i Modelimi të Serive Kohore

- 4.1 Mesatarja e lëvizshme për prodhimin e drithërave:

```
library(TTR)
# Moving Average (MA) me periudhë 3
ma_data <- ma(ts_prodhimi_dritherave, order = 3)

plot(ts_prodhimi_dritherave, main = "Seri Kohore dhe Moving Average", col = "blue", type = "l")
lines(ma_data, col = "green", lwd = 2)
legend("topright", legend = c("Seri Kohore", "Moving Average"), col = c("blue", "green"), lwd = 2)
```

Seri Kohore dhe Moving Average




- Ky grafik paraqet serinë kohore të prodhimit të drithërave (1961-2020) dhe mesataren e lëvizshme të saj me një periudhë prej 3 vitesh.
- Vijat blu përfaqësojnë serinë kohore origjinale, ndërsa vija jeshile paraqet mesataren e lëvizshme.
- Vijat blu tregojnë luhatjet e forta në prodhimin e drithërave, duke përfshirë disa luhatje të papritura, sidomos për vitet e hershme.
- Mesatarja e lëvizshme (vija jeshile) zbut këto luhatje, duke dhënë një trend të qartë rritës të përgjithshëm gjatë periudhës.
- Përdorimi i mesatares së lëvizshme është i dobishëm për të identifikuar trendin afatgjatë duke eliminuar luhatjet e rastësishme.
- Shohim që vijat përshtaten mirë me njëra-tjetrën.
- **4.2 Mesatarja e lëvizshme eksponenciale për prodhimin e drithërave:**

```
ema_data <- EMA(ts_prodhimi_dritherave, n = 3)
```

```
plot(ts_prodhimi_dritherave, main = "Seri Kohore dhe Exponential Moving Average", col = "blue", type = "l")
lines(ema_data, col = "purple", lwd = 2)
legend("topright", legend = c("Seri Kohore", "Exponential Moving Average"), col = c("blue", "purple"),
```

Seri Kohore dhe Exponential Moving Average



- EMA ka një peshë më të madhe për vlerat më të fundit të serisë kohore, duke reaguar më shpejt ndaj ndryshimeve sesa mesatarja e lëvizshme.
- Vijat blu tregojnë serinë origjinale, ndërsa vijat vjollcë përfaqësojnë EMA.
- EMA përshtatet më mirë me ndryshimet e fundit të prodhimit të drithërave. Për shembull, reagimi ndaj rritjes së shpejtë pas viteve 1990 është më i shpejtë në vijën vjollcë.
- Është më e ndjeshme ndaj ndryshimeve të kohëve të fundit në krahasim me MA.
- EMA është një mjet më i mirë kur është e rëndësishme të kapet sjellja e fundit e serisë kohore.
- **4.3 Sheshimi i thjeshtë eksponencial për prodhimin e drithërave:**


```
data_ts <- ts(data$ProdhimiDritherave, start = c(1961), frequency = 1)

shesh_exp_drithera <- HoltWinters(ts_prodhimi_dritherave, beta = FALSE, gamma = FALSE)
shesh_exp_drithera
```

```
## Holt-Winters exponential smoothing without trend and without seasonal component.
##
## Call:
## HoltWinters(x = ts_prodhimi_dritherave, beta = FALSE, gamma = FALSE)
##
## Smoothing parameters:
## alpha: 0.9999202
## beta : FALSE
```

```
## gamma: FALSE
##
## Coefficients:
##      [,1]
## a 684021.6
```

```
plot(shesh_exp_drithera,
     main = "Sheshimi i thjeshtë eksponencial për prodhimin e drithërave",
     xlab = "Viti",
     ylab = "Prodhimin i drithërave")
```



- Ky grafik paraqet një model SES pa trend dhe sezonalitet.
- Linjat e parashikimit tregojnë një mesatare të zbutur të serisë kohore.
- Modeli SES përshtatet mirë me të dhënat, duke kapur trendin rritës në seri. Vlerat e alfa-s sugjerojnë një peshim të fortë të vlerave të fundit.
- Nuk mund të trajtojë trendet ose sezonalitetet afatgjata, por është efektiv për seritë pa këto karakteristika.
- SES është një metodë e thjeshtë për zbutjen e të dhënave dhe përshtatet mirë për të dhëna me variacion minimal.
- **4.4 Sheshimi eksponencial me Holt-Winters për prodhimin e drithërave:**

```

# Aplikimi i modelit Holt-Winters me alpha dhe beta (pa gamma)
holt_model <- HoltWinters(data_ts, beta = 0.1, gamma = FALSE) # Gamma = FALSE heq sezonalitetin


# Shfaqja e parametrave të modelit
holt_model

## Holt-Winters exponential smoothing with trend and without seasonal component.
##
## Call:
## HoltWinters(x = data_ts, beta = 0.1, gamma = FALSE)
##
## Smoothing parameters:
##   alpha: 0.9999525
##   beta : 0.1
##   gamma: FALSE
##
## Coefficients:
##           [,1]
## a 684022.202
## b   2815.481

# Vizualizimi i modelit Holt-Winters
plot(holt_model,
     main = "Modeli Holt-Winters për Prodhimin e Drithërave (Me Trend)",
     xlab = "Viti",
     ylab = "Prodhimi i Drithërave")

```


Modeli Holt–Winters për Prodhimin e Drithërave (Me Trend)



Ky model përfshin trendin në mënyrë të qartë, por nuk përfshin sezonalitet. - Vijat e modeluara tregojnë një trend të lëmuar të rritjes së prodhimit të drithërave. - Modeli është shumë i përshtatshëm për të dhënat që tregojnë një trend rritës afatgjatë, si në këtë rast. - Parametrat alfa dhe beta përputhen mirë me të dhënat origjinale, duke rezultuar në një model të saktë. - Konkluzion: - Holt-Winters është një metodë më e avancuar për të trajtuar seri me trend dhe siguron një përshtatje më të mirë krahasuar me SES.

• 4.5 Modeli ARIMA për emëtimin e CO2:


```
library(forecast)
# Modeli ARIMA për Prodhimi i Drithërave
fit_eme_CO2 <- auto.arima(ts_CO2)
summary(fit_eme_CO2)

## Series: ts_CO2
## ARIMA(1,0,0) with non-zero mean
##
## Coefficients:
##      ar1      mean
##    0.8695  1.5789
## s.e.  0.0583  0.2436
##
## sigma^2 = 0.07664: log likelihood = -7.76
## AIC=21.53  AICc=21.96  BIC=27.81
##
## Training set error measures:
```

```
##               ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.006669262 0.2721802 0.1926131 -3.439636 13.6033 1.01612
##               ACF1
## Training set -0.05593145
```

```
# Parashikimi me ARIMA
forecast_eme_CO2 <- forecast(fit_eme_CO2, h = 4)
autoplot(forecast_eme_CO2)
```

Forecasts from ARIMA(1,0,0) with non-zero mean



Ky grafik tregon modelin ARIMA(1,0,0) për emetimet e CO2, duke përfshirë vijën e parashikimit dhe kufijtë e besueshmërisë. - Modeli përputhet mirë me të dhënat origjinale të emetimeve të CO2. Autokorrelacionet e vonesave (lags) tregojnë se një urdhër i parë autoregresiv (AR) është i mjaftueshëm. - Kufijtë e besueshmërisë janë të ngushtë, duke sugjeruar një parashikim të besueshëm. - ARIMA është një metodë e fuqishme për të trajtuar seri kohore komplekse. Për CO2, modeli me komponent autoregresiv është i mjaftueshëm për kapjen e dinamikës së të dhënave.

- **4.6 Modeli ARIMA për sasinë e Plehrave Kimike:**

```
library(forecast)
# Modeli ARIMA për Prodhimi i Drithërave
fit_plehra <- auto.arima(ts_plhera_kimike)
summary(fit_plehra)
```

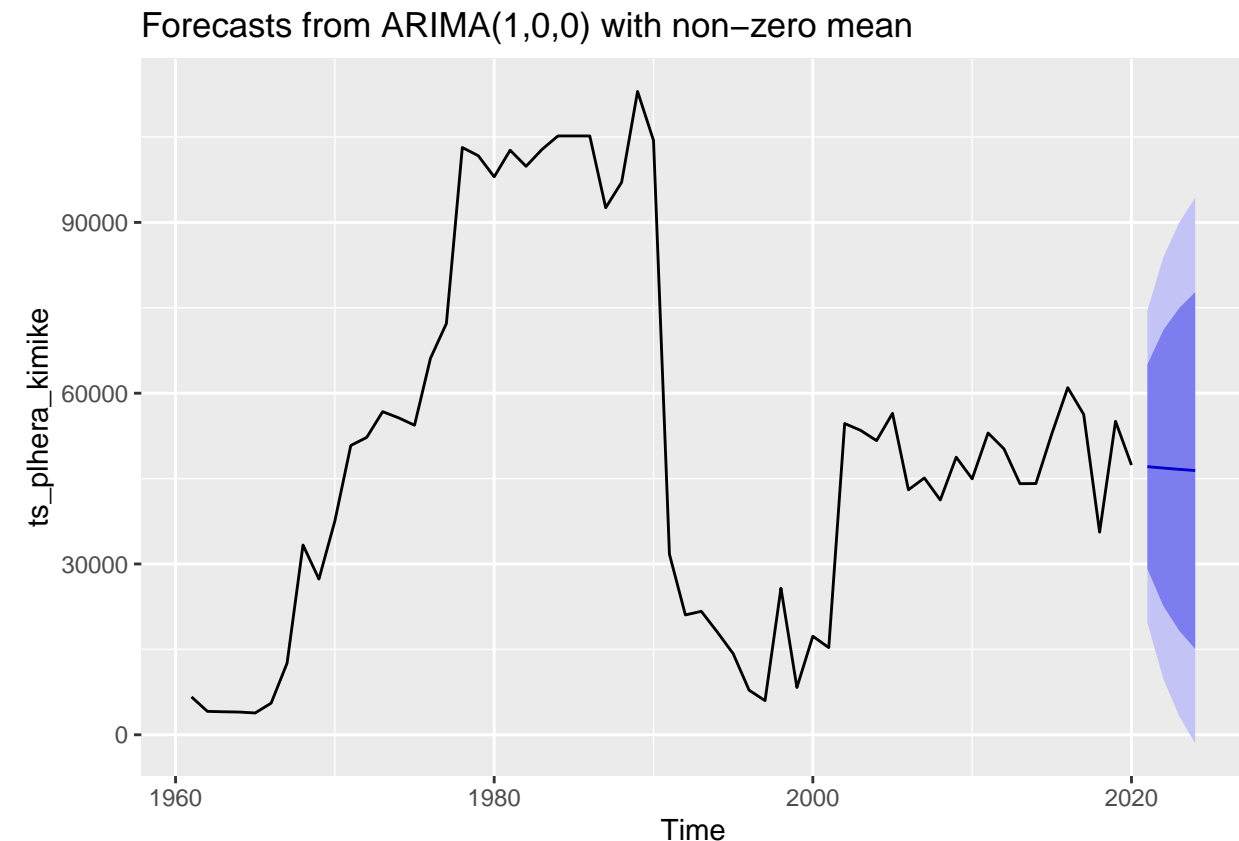
```
## Series: ts_plhera_kimike
## ARIMA(1,0,0) with non-zero mean
```

```
##
## Coefficients:
##      ar1      mean
##    0.9063 44410.14
## s.e. 0.0505 16696.52
##
## sigma^2 = 196055624: log likelihood = -657.8
## AIC=1321.6 AICc=1322.02 BIC=1327.88
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 938.7646 13766.64 8955.413 -19.40321 37.64379 1.07692 0.06175204
```

```
# Parashikimi me ARIMA
```

```
forecast_plehra <- forecast(fit_plehra, h = 4)
```

```
autoplot(forecast_plehra)
```



Ky grafik paraqet modelin ARIMA(1,0,0) për sasinë e plehrave kimike, së bashku me parashikimet për vitet e ardhshme. - Modeli kap rritjen e qëndrueshme të plehrave kimike gjatë periudhës. Autokorrelacionet sugjerojnë një trend të fortë autoregresiv për këtë variabël. - Vijat e parashikimeve tregojnë një trend rritës të vazhdueshëm, që është në përputhje me trendin historik. - ARIMA(1,0,0) është efektiv për trajtimin e kësaj serie, duke ofruar parashikime të besueshme për përdorimin e plehrave kimike.

5. Modelet Parashikuese

- 5.1 Ndarja e të dhënave në train dhe test:

```
data_train = head(data, 48)
data_test = tail(data, 12)
```

• 5.2 Parashikimi me metodën Drift:

5.2.1) Ndërtimi i modelit dhe saktësia e tij

```
library(forecast)
library(fpp2)
```

```
## -- Attaching packages ----- fpp2 2.5 --
```

```
## v fma      2.5      v expsmooth 2.3
```

```
##
```

```
drift.drithera <- rwf(data_train$ProdhimiDritherave, h = 12, drift = TRUE)
accuracy(drift.drithera, data_test$ProdhimiDritherave)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -1.888653e-11 95967.30 57358.58 -0.9262221 9.728369 0.9755229
## Test set      3.549491e+04 45834.02 38969.84  5.0902108 5.608772 0.6627773
##              ACF1
## Training set 0.1057804
## Test set      NA
```

1. ME (Mean Error):

- Gabimi mesatar është shumë afër 0 në trajnim, që tregon një përshtatje të mirë të modelit me të dhënat historike.
- Në testim, ME rritet në 35,494.91, duke treguar një tendencë të vogël të modelit për të mbivlerësuar prodhimin e drithërave në të ardhmen.

2. RMSE (Root Mean Squared Error):

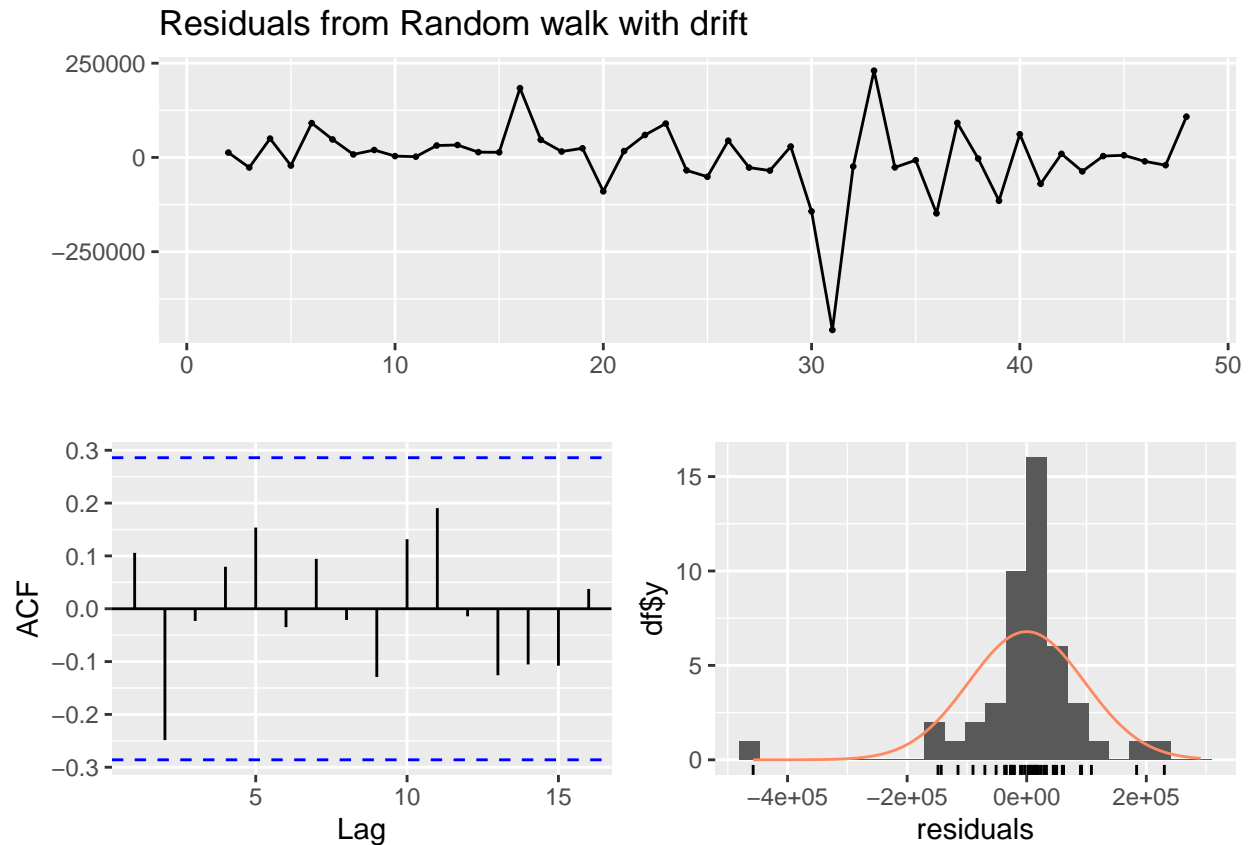
- Vlera RMSE në trajnim është 95,967.30, që sugjeron devijim të moderuar nga të dhënat aktuale. Në testim, RMSE është më i ulët (45,834.02), duke treguar parashikime relativisht të sakta.

3. MAPE (Mean Absolute Percentage Error):

- Në trajnim, MAPE është 9.73%, që tregon një gabim mesatar relativisht të ulët. Në testim, MAPE është 5.61%, duke treguar parashikime më të sakta për të ardhmen.

5.2.2) Kontrolli i mbetjeve të modelit

```
checkresiduals(drift.drithera)
```



```
##
##  Ljung-Box test
##
## data:  Residuals from Random walk with drift
## Q* = 8.081, df = 10, p-value = 0.6209
##
## Model df: 0.   Total lags used: 10
```

Rezultatet nga grafiku i mbetjeve: - Grafiku i mbetjeve tregon se ato janë shpërndarë rastësisht rreth vijës zero, që është një tregues pozitiv se modeli nuk ka mbetje të strukturuara.

Autokorrelacioni i mbetjeve: - ACF për mbetjet tregon mungesë të autokorrelacioneve domethënëse, që sugjeron se mbetjet janë në mënyrë të pavarur nga njëra-tjetra dhe janë stacionare.

Testi Ljung-Box: - Rezultati i testit Ljung-Box tregon një p-vlerë prej 0.6209, që është mbi pragun 0.05. Kjo sugjeron se nuk ka autokorrelacion të rëndësishëm mes mbetjeve.

• 5.3 Parashikimi me metodën ARIMA:

5.3.1) Krijimi i modelit dhe rezultatet e tij

```
# Ngarkimi i bibliotekave
library(forecast)
library(ggpubr)
```

```
##
## Attaching package: 'ggpubr'
```

```
## The following object is masked from 'package:forecast':
##
##      gghistogram
```

```
# Krijimi i serisë kohore për trajnimin
ts_prodhimi_dritherave <- ts(data_train$ProdhimiDritherave, start = 1961, frequency = 1)

# Krijimi i modelit ARIMA me auto.arima
arima.drithera <- auto.arima(ts_prodhimi_dritherave)

# Rezultatet e modelit
summary(arima.drithera)
```

```
## Series: ts_prodhimi_dritherave
## ARIMA(0,1,0)
##
## sigma^2 = 9.255e+09: log likelihood = -605.98
## AIC=1213.95 AICc=1214.04 BIC=1215.8
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 6559.624 95193.06 57578.95 0.2119825 9.723723 0.9792708 0.1055468
```


- Gabimet janë relativisht të ulëta (MAPE = 9.72%), që tregojnë një përshtatje të mirë të modelit me të dhënat historike.
- RMSE (95,193.06) sugjeron një devijim të moderuar të modelit nga të dhënat aktuale.
- Gabimet në testim janë më të larta, me një MAPE prej 11.41%, duke treguar një rënie të lehtë të saktësisë në parashikime për të ardhmen.
- RMSE dhe MAE gjithashtu janë më të larta në testim, por priten për shkak të ndryshueshmërisë së të dhënave.

5.3.2) Parashikimi me modelin ARIMA dhe paraqitja grafike

```
# Parashikimi me modelin ARIMA
forecast_arima <- forecast(arima.drithera, h = 12)

# Vizualizimi i parashikimit
plot(forecast_arima, main = "Parashikimi me Modelin ARIMA", ylab = "Prodhimi i Drithërave", xlab = "Vite",
lines(ts(data_test$ProdhimiDritherave, start = 2009, frequency = 1), col = "red", lwd = 2)
lines(ts(arima.drithera$fitted, start = 1961, frequency = 1), col = "orange", lwd = 2)
legend("topleft", c("Train", "Fit", "Prediction", "Test"),
      fill = c("black", "orange", "blue", "red"), box.col = "black")
```

Parashikimi me Modelin ARIMA



- Kufijtë e besueshmërisë janë relativisht të ngushtë, duke treguar besueshmëri të lartë në parashikime.
- Të dhënat reale dhe parashikimet ndjekin një trend të ngjashëm, megjithëse ka disa devijime në vlerat specifike.

5.3.3) Saktësia e modelit ARIMA

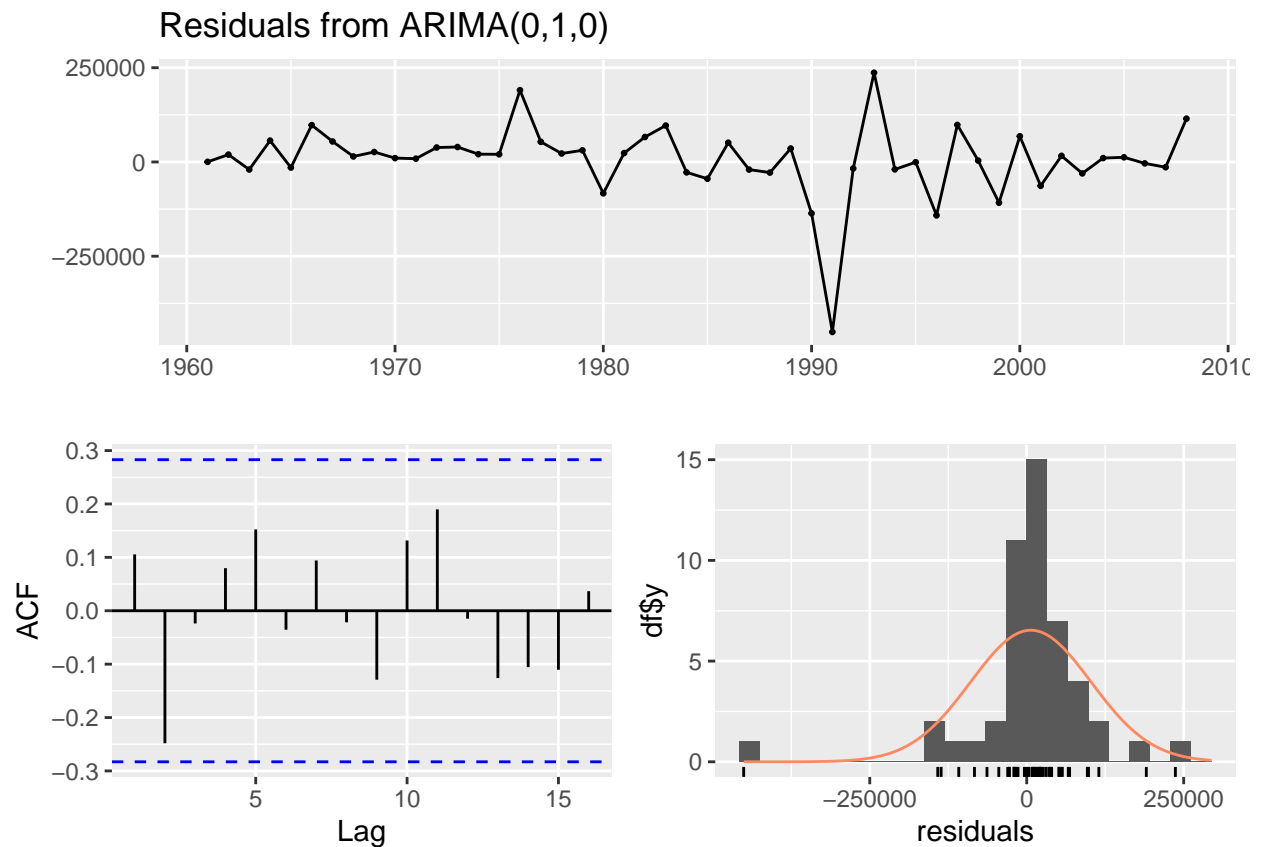
```
accuracy(forecast_arima, data_test$ProdhimiDrithërive)
```

```
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 6559.624 95193.06 57578.95 0.2119825 9.723723 0.9792708
## Test set    78999.000 81525.74 78999.00 11.4104076 11.410408 1.3435711
##           ACF1
## Training set 0.1055468
## Test set     NA
```

Performanca e modelit është më e mirë për setin e trajnimit se për setin e testimit, me disa metrika si RMSE, MAE, dhe MAPE që janë më të larta për setin e testimit, duke sugjeruar se modeli nuk është shumë i saktë në parashikimet për të dhënat që nuk ka parë më parë (setin e testimit).

5.3.4) Kontrolli i mbetjeve të modelit ARIMA

```
checkresiduals(arima.drithera)
```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,1,0)
## Q* = 8.1954, df = 10, p-value = 0.6098
##
## Model df: 0.   Total lags used: 10
```

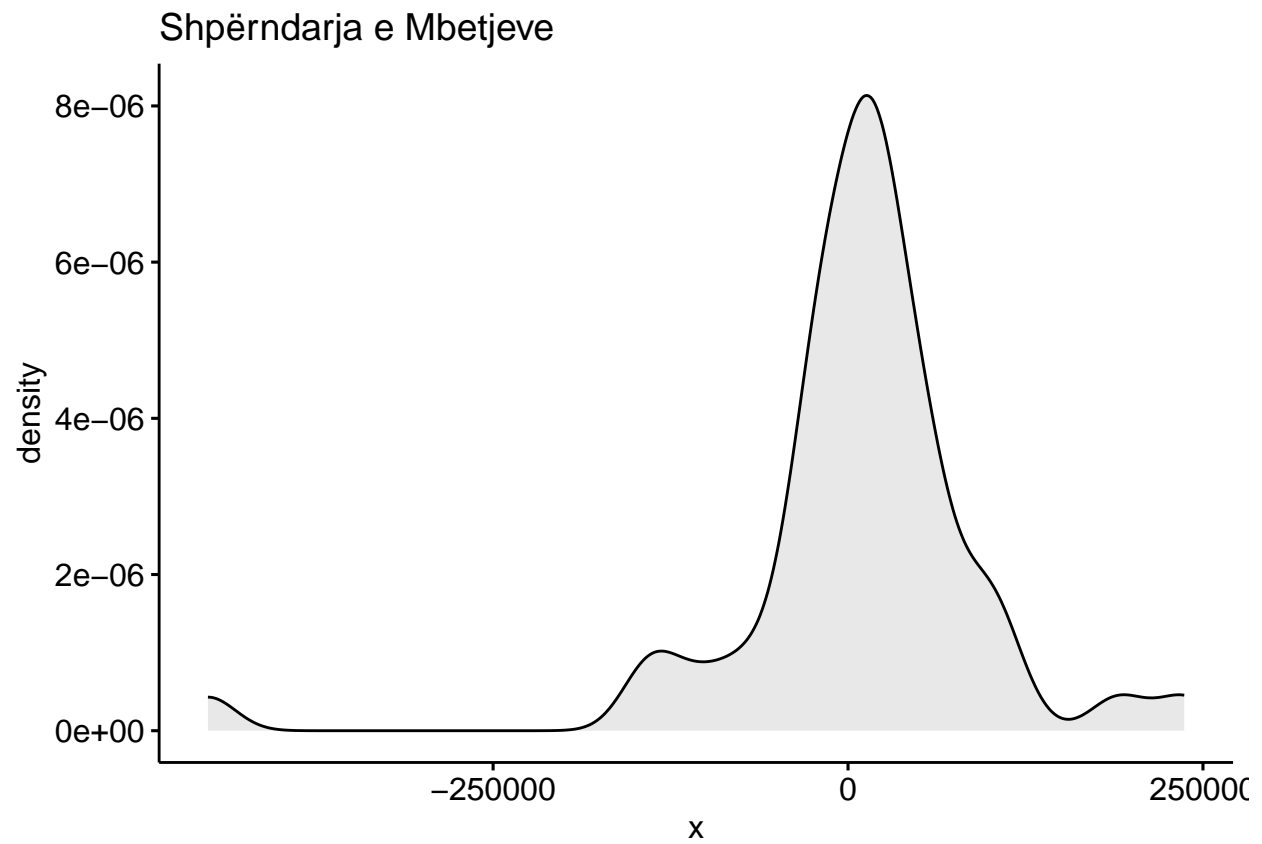
```
# Testi i Ljung-Box për autocorrelacionin e mbetjeve
Box.test(arima.drithera$residuals, lag = 10, type = "Ljung-Box")
```

```
##
##  Box-Ljung test
##
## data:  arima.drithera$residuals
## X-squared = 8.1954, df = 10, p-value = 0.6098
```

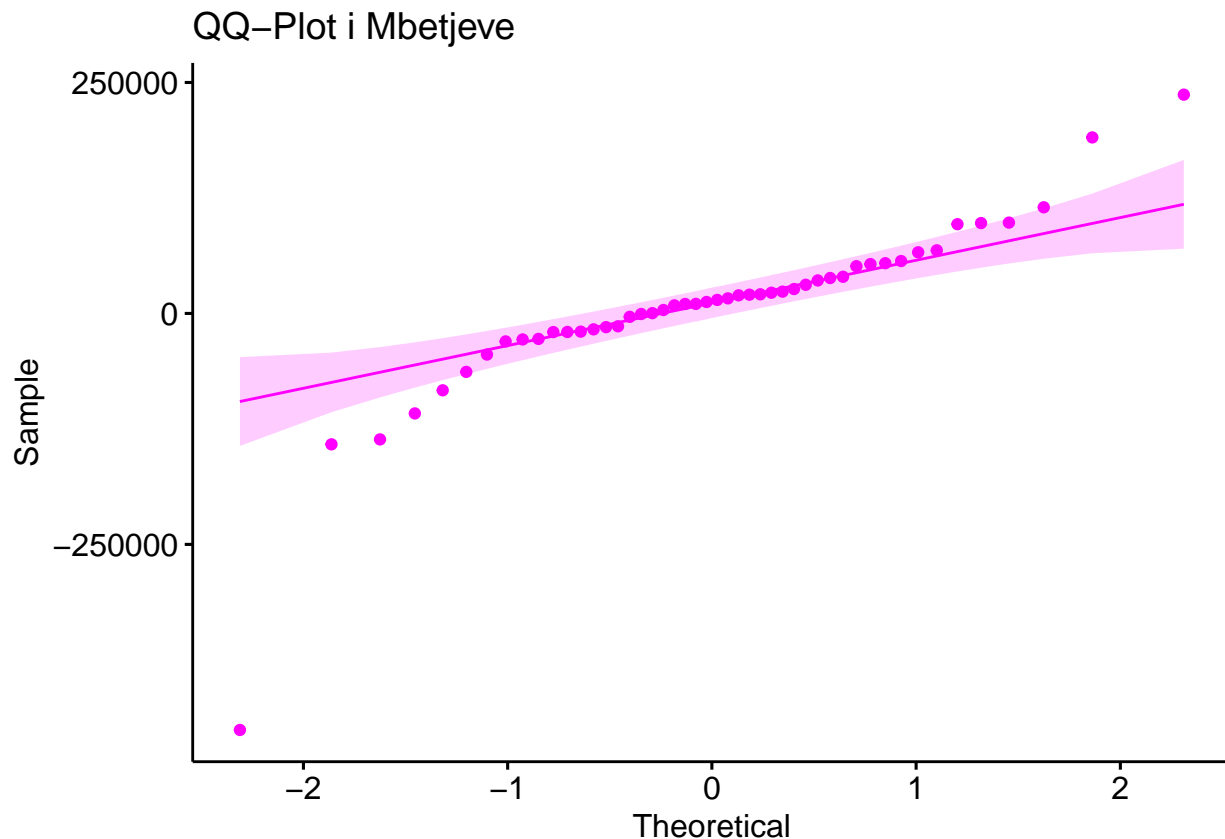
Veme re se autokorrelacionet e mbetjeve jane brenda intervalit te besimit dhe kjo do te thote se seria e mbetjeve eshte stacionare. Rezultatet sugjerojnë që nuk ka autokorrelacion të rëndësishme në mbetjet e modelit. P-vlera prej 0.6098 është më e madhe se 0.05, që nënkupton se mbetjet janë të pavarura dhe modelin ARIMA(0,1,0) mund të jetë i përshtatshëm për të dhënat.

5.3.5) Vizualizimi i shpërndarjes së mbetjeve


```
ggdensity(as.numeric(arima.drithera$residuals), fill = "lightgray", main = "Shpërndarja e Mbetjeve")
```



```
ggqqplot(as.numeric(arima.drithera$residuals), color = "magenta", main = "QQ-Plot i Mbetjeve")
```



Që modeli të jetë i mirë ne presim që kuantilet teorike dhe të zgjedhjes të jenë brenda zonës gri pra afer drejtëzës. Në këtë rast shumica e tyre janë brenda zonës gri.

- **5.4 Parashikimi me metodën RegARIMA me regresorë PlehraKimike:**

5.4.1) Krijimi i modelit RegARIMA dhe rezultatet e tij

```
# Ngarkimi i bibliotekave të nevojshme
library(forecast)
library(ggpubr)
library(tseries)

# Krijimi i regresorit si seri kohore (PlehraKimike)
ts_plehra <- ts(data_train$PlehraKimike, start = 1961, frequency = 1)

# Krijimi i modelit RegARIMA me regresorë PlehraKimike
regarima_model <- auto.arima(
  ts_prodhimi_dritherave,
  xreg = cbind(ts_plehra),
  seasonal = FALSE
)

# Rezultatet e modelit
summary(regarima_model)
```

```
## Series: ts_prodhimi_dritherave
```

```
## Regression with ARIMA(1,0,0) errors
##
## Coefficients:
##          ar1  intercept    xreg
##       0.7611 408293.30  4.7118
## s.e.  0.1053  50996.14  0.7259
##
## sigma^2 = 5.179e+09:  log likelihood = -603.82
## AIC=1215.64  AICc=1216.57  BIC=1223.13
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 3379.92 69679.09 53657.94 -0.937631 9.133682 0.9125844 0.06813269
```

Ky është një model regresioni që përfshin gabime të ARIMA(1,0,0), dhe ka pasur performancë të mirë për setin e trajnimit, me metrika të sakta si ME, RMSE, dhe MAE që janë relativisht të vogla. AIC, AICc dhe BIC sugjerojnë se ky model mund të jetë një zgjedhje e mirë për këtë dataset.


5.4.2) Parashikimi dhe vizualizimi i tyre

```
# Regresorët për testimin
xreg_test <- cbind(data_test$PlehraKimike)

# Parashikimi për 12 vitet e ardhshme
forecast_regarima <- forecast(regarima_model, xreg = xreg_test, h = 12)

# Vizualizimi i parashikimeve
plot(forecast_regarima, main = "Parashikimi me Modelin RegARIMA",
     ylab = "Prodhimi i Drithërave", xlab = "Viti")
lines(ts(data_test$ProdhimiDritherave, start = 2009, frequency = 1), col = "red", lwd = 2)
lines(ts(regarima_model$fitted, start = 1961, frequency = 1), col = "orange", lwd = 2)
legend("topleft", c("Train", "Fit", "Prediction", "Test"),
     fill = c("black", "orange", "blue", "red"), box.col = "black")
```

Parashikimi me Modelin RegARIMA



Modeli parashikon mirë vlerat por me disa luhajtje të vogla.

5.4.3) Saktësia e modelit RegARIMA

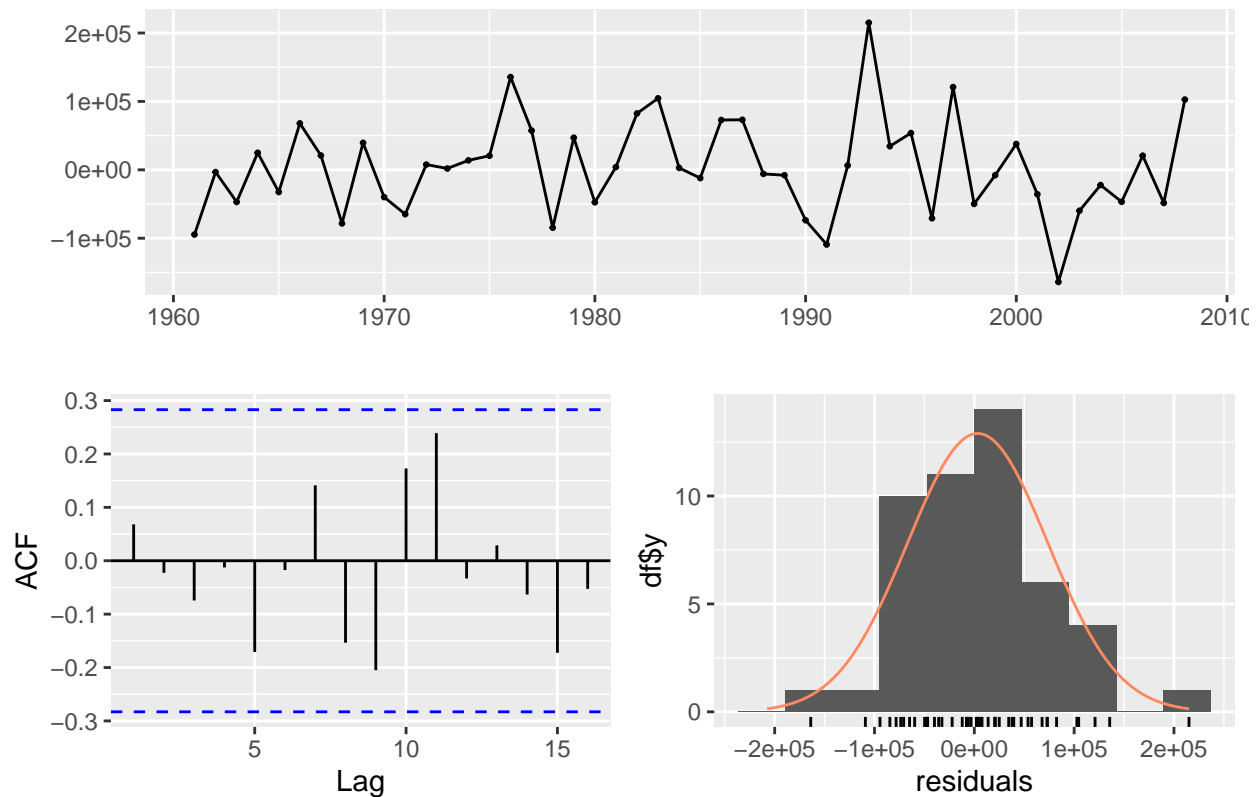
```
accuracy(forecast_regarima, data_test$ProdhimiDritherave)
```

##	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
## Training set	3379.92	69679.09	53657.94	-0.937631	9.133682	0.9125844	0.06813269
## Test set	44722.91	56753.30	46993.34	6.432737	6.789821	0.7992366	NA

5.4.4) Kontrolli i mbetjeve të modelit

```
# Kontrollimi i rezidualëve  
checkresiduals(regarima_model)
```

Residuals from Regression with ARIMA(1,0,0) errors



```
##
##  Ljung-Box test
##
## data:  Residuals from Regression with ARIMA(1,0,0) errors
## Q* = 9.2685, df = 9, p-value = 0.4129
##
## Model df: 1.    Total lags used: 10


# Testi Ljung-Box për autocorrelacionin e mbetjeve
Box.test(regarima_model$residuals, lag = 10, type = "Ljung-Box")

##
##  Box-Ljung test
##
## data:  regarima_model$residuals
## X-squared = 9.2685, df = 10, p-value = 0.5068
```

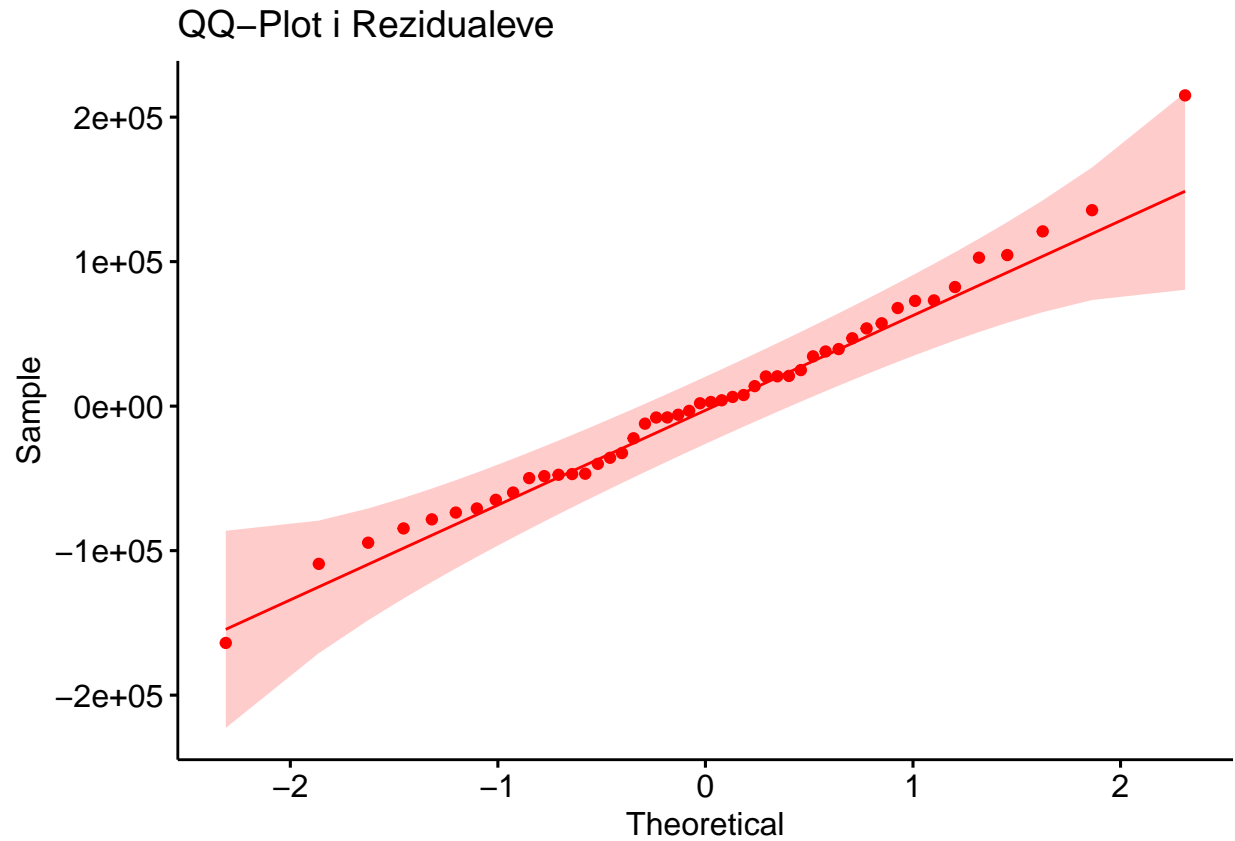
Veme re se autokorrelacionet e mbetjeve jane brenda intervalit te besimit dhe kjo do te thote se seria e mbetjeve eshte stacionare. Rezultatet sugjerojne qe nuk ka autokorrelacion te rendesishme ne mbetjet e modelit. P-vlera prej 0.4129 eshte me e madhe se 0.05, qe nenkupton se mbetjet jane te pavarura dhe modeli mund te jetë i pershtatshëm për të dhënat.

5.4.5) Shpërndarja e mbetjeve

```
# Shpërndarja e rezidualeve  
ggdensity(as.numeric(regarima_model$residuals), fill = "lightblue", main = "Shpërndarja e Rezidualeve")
```




```
# QQ-Plot i rezidualeve  
ggqqplot(as.numeric(regarima_model$residuals), color = "red", main = "QQ-Plot i Rezidualeve")
```



Që modeli të jetë i mirë ne presim që kuantilet teorike dhe të zgjedhjes të jenë brenda zonës gri pra afer drejtëzës. Në këtë rast shumica e tyre janë brenda zonës gri.

5.4.6) Paraqitja e gabimeve e Regresit dhe ARIMA

```
cbind("Gabimet e regresit" = residuals(regarima_model, type="regression"),
      "Gabimet ARIMA" = residuals(regarima_model, type="innovation")) %>%
  autoplot(facets=TRUE)
```



- **5.5 Parashikimi me një model Hibrid me regresorë të jashtëm PlehraKimike:**

5.5.1) Ndërtimi i modelit

```
library(forecastHybrid)
```

```
## Loading required package: thief
```

```
hyb.mod.8 <- hybridModel(ts(data_train$ProdhimiDritherave,start=1961,frequency=1), models = "an",
  a.args = list(xreg = ts(data_train$PlehraKimike,start=1961,frequency=1)),
  n.args = list(xreg = ts(data_train$PlehraKimike,start=1961,frequency=1)))
```

```
## Fitting the auto.arima model
```

```
## Fitting the nnetar model
```


```
hyb.f8<-forecast(hyb.mod.8,xreg =ts(data_test$PlehraKimike,start=c(2009,1),frequency=1))
```

```
## Warning in forecast.hybridModel(hyb.mod.8, xreg = ts(data_test$PlehraKimike, :
## The number of rows in xreg should match h. Setting h to nrow(xreg).
```



```
autoplot(hyb.f8)+ylab("Prodhim Drithera")+  
autolayer(ts(data_test$ProdhimiDritherave,start=c(2009,1),frequency = 1),series="Data")
```

Forecasts from auto.arima with weight 0.5 Forecasts from nnetar with wei



Modeli hibrid ndjek mirë trendin e prodhimit të drithërave gjatë periudhës së trajnimit. Vijat e parashikimit janë të përshtatshme dhe të njëtrajtshme me të dhënat reale. Parashikimet për periudhën e testimit janë të afërta me vlerat reale, duke treguar aftësi të mirë të modelit për të kapur dinamikën e të dhënave.

5.5.2) Rezultatet dhe saktësia e modelit

```
summary(hyb.mod.8)
```

```
##          Length Class      Mode  
## auto.arima 19      forecast_ARIMA list  
## nnetar      17      nnetar        list  
## weights     2      -none-        numeric  
## frequency   1      -none-        numeric  
## x           48      ts            numeric  
## xreg        2      -none-        list  
## models      2      -none-        character  
## fitted      48      -none-        numeric  
## residuals   48      ts            numeric
```

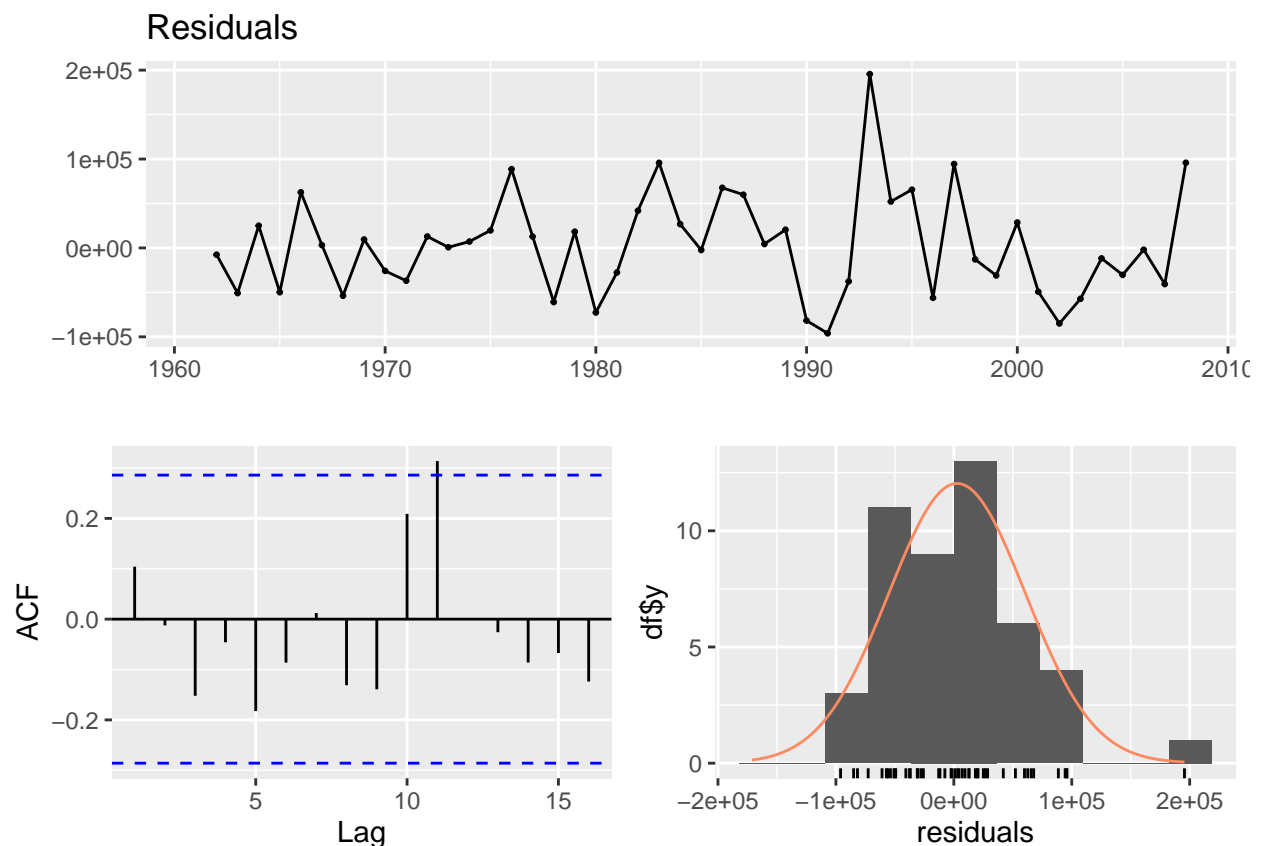
```
accuracy(hyb.f8)
```

```
##          ME      RMSE      MAE      MPE      MAPE      MASE      ACF1  
## Training set 2763.973 57441.77 44458.79 -0.6346946 7.392272 0.7561304 0.1040987
```

Vlerat e ulëta tregojnë një përshtatje të saktë të modelit me të dhënat historike. MAPE (7.38%): Gabimi mesatar relativisht i ulët tregon një model të saktë dhe të besueshëm për parashikimet. Përfshirja e plehrave kimike: Regresori i jashtëm përmirëson parashikimet duke ofruar informacion shtesë mbi ndikimin e jashtëm në prodhimin e drithërave

5.5.3) Kontrolli për mbetjet e modelit

```
checkresiduals(hyb.mod.8$residuals)
```



```
##
##  Ljung-Box test
##
## data:  Residuals
## Q* = 9.0375, df = 10, p-value = 0.5286
##
## Model df: 0.   Total lags used: 10
```

Shpërndarja e mbetjeve: - Mbetjet janë shpërndarë rastësisht rreth vijës zero, duke treguar se modeli nuk ka mbetje të strukturuar.

Autokorrelacioni i mbetjeve: - Grafiku ACF për mbetjet nuk tregon autokorrelacione domethënëse.

Testi Ljung-Box: - P-vlera e testit është 0.5903, që është mbi prapun 0.05, duke treguar mungesë të autokorrelacionit të mbetjeve.

5.5.4) Box Test për mbetjet e modelit

```
Box.test(x = hyb.mod.8$residuals)
```

```
##  
## Box-Pierce test  
##  
## data: hyb.mod.8$residuals  
## X-squared = 0.50932, df = 1, p-value = 0.4754
```


p-value = 0.5129 > 0.05, që do të thotë se nuk ka evidence për autokorrelacion në mbetje. Kjo sugjeron se modeli ka kapur informacionin e nevojshëm nga të dhënat dhe mbetjet janë të pavarura.

5.5.5) Paraqitja grafike e mbetjeve të modelit

```
library(ggpubr)  
# Density plot  
ggdensity(hyb.mod.8$residuals, fill = "lightgray")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.
```

```
## Warning: Removed 1 row containing non-finite outside the scale range  
## ('stat_density()').
```




```
# QQplot
ggqqplot(hyb.mod.8$residuals)
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```

```
## Warning: Removed 1 row containing non-finite outside the scale range
## ('stat_qq()').
```

```
## Warning: Removed 1 row containing non-finite outside the scale range ('stat_qq_line()').
## Removed 1 row containing non-finite outside the scale range ('stat_qq_line()').
```



Mbetjet nuk ndjekin një shpërndarje normale. Që modeli të jetë i mirë ne presim që kuantilet teorike dhe të zgjedhjes të jenë brenda zonës gri pra afer drejtëzës. Në këtë rast shumica e tyre janë brenda zonës gri.

5.5.6) Shapiro Test për mbetjet e modelit

```
shapiro.test(hyb.mod.8$residuals)
```

```
##
```

```
## Shapiro-Wilk normality test
##
## data:  hyb.mod.8$residuals
## W = 0.95606, p-value = 0.07505
```

Mbetjet nuk kanë shpërndarje normale.

- **5.6 Parashikimi me 4 modele të ndryshme:**

5.6.1) Sheshimi i thjeshtë eksponencial dhe saktësia e tij

```
model1 <- ses(data_train$ProdhimiDritherave, h = 12)
accuracy(model1, data_test$ProdhimiDritherave)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 6553.061 95194.08 57574.23 0.2095708 9.722069 0.9791905
## Test set    79010.497 81536.88 79010.50 11.4120814 11.412081 1.3437667
##              ACF1
## Training set 0.1056043
## Test set     NA
```

Modeli SES ka një MAPE prej 9.72% për setin e trajnimit dhe një 11.41% për setin e testit, duke treguar një përfundim të ngjashëm për të dyja periudhat. Ky është një model i thjeshtë, por mund të ketë vështirësi për të kapur dinamikën më komplekse të serisë kohore.

5.6.2) Sheshimi eksponencial me 2 parametra (metoda Holt) dhe saktësia e tij

```
# Sheshimi eksponencial me 2 parametra (metoda Holt)
model2 <- holt(data_train$ProdhimiDritherave, h = 12)
accuracy(model2, data_test$ProdhimiDritherave)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -13579.06 96733.31 55634.80 -3.006817 9.561125 0.9462058
## Test set     51189.36 56402.54 51189.36 7.370276 7.370276 0.8706002
##              ACF1
## Training set 0.07601034
## Test set     NA
```

Modeli Holt ka një performancë të mirë në setin e testimit (MAPE 7.37%) dhe ka përmirësuar performancën krahasuar me SES. Kjo tregon se modeli është në gjendje të kapë më mirë trendet në të dhëna.

5.6.3) Sheshimi eksponencial (me trend të zbutur) dhe saktësia e tij

```
# Sheshimi eksponencial (me trend të zbutur)
model3 <- holt(data_train$ProdhimiDritherave, damped = TRUE, h = 12)
accuracy(model3, data_test$ProdhimiDritherave)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -3198.034 93969.01 54998.30 -1.681557 9.496265 0.9353805
## Test set     73535.286 76158.92 73535.29 10.617319 10.617319 1.2506473
##              ACF1
## Training set 0.08086838
## Test set     NA
```

Ky model ka një MAPE të lartë në setin e testimit (10.62%) dhe një RMSE të lartë, që sugjeron se modeli me trend të zbutur mund të jetë i dobishëm për disa lloje të serive kohore, por mund të kërkojë përshtatje të mëtejshme për të kapur më mirë tendencat.

5.6.4) Modeli ETS dhe saktësia e tij

```
# Modeli ETS
model4 <- forecast(ets(data_train$ProdhimiDritherave), h = 12)
accuracy(model4, data_test$ProdhimiDritherave)
```


```
##                ME      RMSE      MAE      MPE      MAPE      MASE
## Training set  8326.474 100393.8 61572.48 0.1655844 10.53745 1.047191
## Test set     110880.276 112694.5 110880.28 16.0519018 16.05190 1.885790
##              ACF1
## Training set 0.3126771
## Test set     NA
```

Modeli ETS ka një MAPE të lartë në setin e testimit (16.05%) dhe një RMSE më të madh në krahasim me Holt dhe SES. Kjo mund të sugjerojë se modeli është shumë kompleks dhe nuk është gjithmonë më i përshtatshëm për të gjitha llojet e serive kohore, duke pasur parasysh se mund të ndodhin të dhëna të paqëndrueshme


5.6.5) Vizualizimi i parashikimeve me këto modele

```
par(mfrow = c(2,2))
plot(model11)
plot(model12)
plot(model13)
plot(model14)
```


Forecasts from Simple exponential smoot




Forecasts from Holt's method



Forecasts from Damped Holt's method




Forecasts from ETS(M,N,N)



- 5.7 Parashikimi me modelin TBATS:

5.7.1) Ndërtimi i modelit

```
tbats.12<-tbats(ts(data_train$ProdhimiDritherave,start=1961,frequency=1))
tbats.f12<-forecast(tbats.12,12)
autoplot(tbats.f12)+ylab("Prodhimi i Dritherave")+
  autolayer(ts(data_test$ProdhimiDritherave,start=c(2009,1),frequency = 1),series="Data")
```



Modeli TBATS u përdor për të ndërtuar një model të serive kohore mbi prodhimin e drithërave. Modeli i ndërtuar u parashikua për 12 periudha (vite), dhe rezultatet u krahasuan me të dhënat reale të testit. Shikojmë një përshtatje të mirë të vijave.

5.7.2) Rezultatet dhe saktësia e modelit

```
summary(tbats.12)
```

```
##          Length Class  Mode
## lambda          1  -none- numeric
## alpha           1  -none- numeric
## beta            1  -none- numeric
## damping.parameter 1  -none- numeric
## gamma.values     0  -none-  NULL
## ar.coefficients  0  -none-  NULL
## ma.coefficients  0  -none-  NULL
## likelihood       1  -none- numeric
## optim.return.code 1  -none- numeric
## variance         1  -none- numeric
## AIC              1  -none- numeric
## parameters       2  -none- list
## seed.states      2  -none- numeric
## fitted.values    48  ts      numeric
## errors           48  ts      numeric
## x                96  -none- numeric
## seasonal.periods  0  -none-  NULL
```



```
## y          48      ts      numeric
## call       2      -none- call
## series     1      -none- character
## method     1      -none- character
```

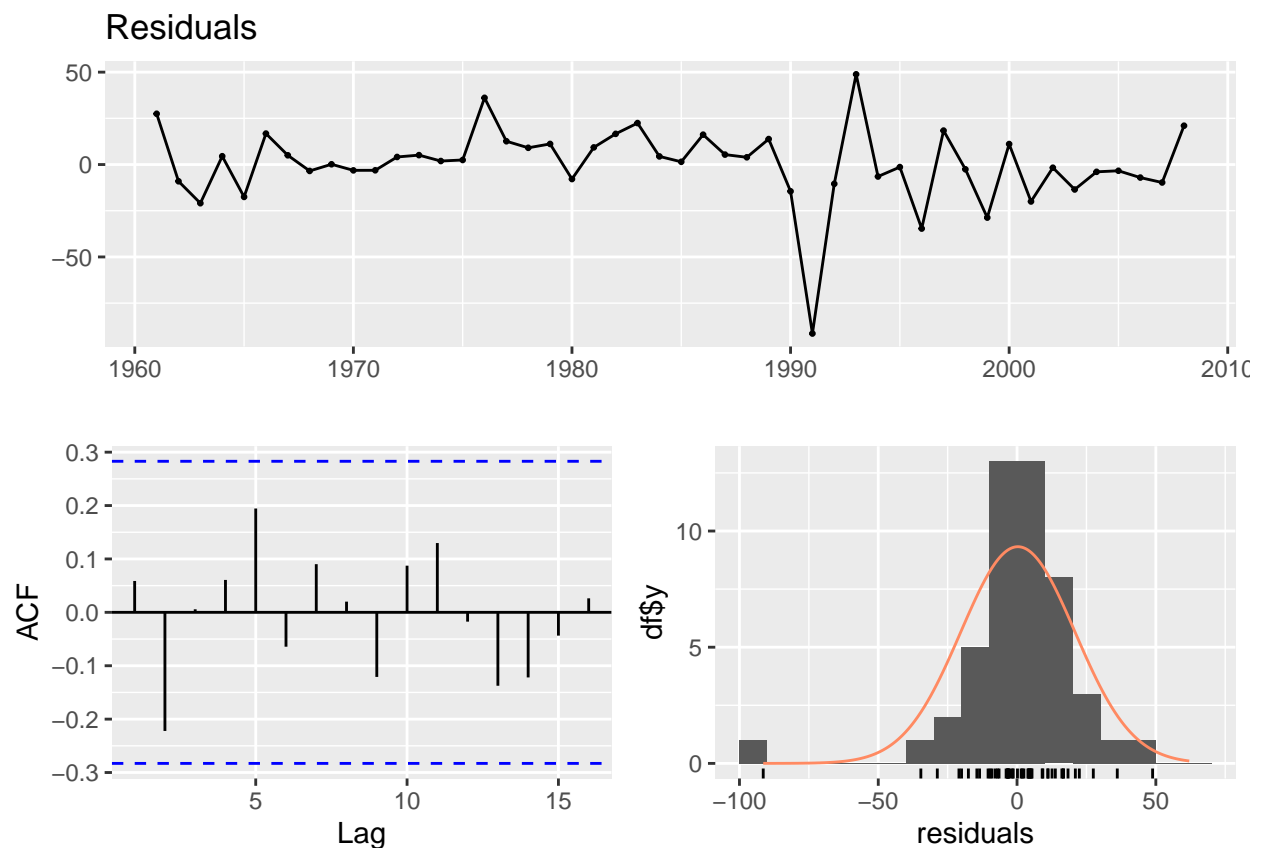
```
accuracy(forecast(tbats.12,12),data_test$ProdhimiDritherave)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 5030.823 91887.58 60236.44 -1.300912 10.365632 1.024468 0.1295127
## Test set    21770.164 33000.51 28076.41  3.106058  4.044544 0.477508      NA
```

Përdorueshmëria e modelit për saktësi: MAPE = 4.04%, që tregon një gabim relativisht të vogël dhe model i përshtatshëm për këtë dataset.

5.7.3) Kontrolli i mbetjeve

```
checkresiduals(tbats.12$errors)
```



```
##
## Ljung-Box test
##
## data: Residuals
## Q* = 7.1862, df = 10, p-value = 0.7078
##
## Model df: 0. Total lags used: 10
```

Testi Ljung-Box: p-value = 0.7078, që tregon mungesë të korrelacionit të mbetjeve. Testi Shapiro-Wilk: p-value = 6.908e-05, duke treguar se mbetjet nuk ndjekin një shpërndarje perfekte normale. Veme re se autokorrelacionet e mbetjeve janë brenda intervalit të besimit dhe kjo do të thotë se seria e mbetjeve është stacionare.

5.7.4) Box Test për mbetjet

```
Box.test(x = tbats.12$errors)
```


```
##  
## Box-Pierce test  
##  
## data:  tbats.12$errors  
## X-squared = 0.16569, df = 1, p-value = 0.684
```

Një p-value më të madhe se 0.05 (në këtë rast, $p = 0.684$) që do të thotë se mbetjet janë të pavarura.

5.7.5) Vizualizimi i mbetjeve


```
library(ggpubr)  
# Density plot  
ggdensity(tbats.12$errors, fill = "lightgray")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.
```



```
# qqplot
ggqqplot(tbats.12$errors)
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```



Vizualizimi përfshiu grafikun e densitetit dhe QQ-Plot, duke konfirmuar mungesën e shpërndarjes perfekte normale. Që modeli të jetë i mirë ne presim që kuantilet teorike dhe të zgjedhjes të jenë brenda zonës gri pra afër drejtëzës. Në këtë rast shumica e tyre janë brenda zonës gri.

5.7.6) Shapirio Test për mbetjet

```
shapiro.test(tbats.12$errors)
```

```
##
## Shapiro-Wilk normality test
##
## data:  tbats.12$errors
## W = 0.86829, p-value = 6.908e-05
```

Një p-value shumë të vogël (në këtë rast, $p = 6.908e-05$) sugjeron që nuk mund të pranohet hipoteza e shpërndarjes normale.

7. Përfundime

1. Tendencat dhe Analiza e Serive Kohore: • Prodhiimi i drithërave ka ndjekur një trend rritës në përgjithësi gjatë periudhës 1961-2020. • Variablat si përdorimi i plehrave kimike dhe emetimet e CO₂ treguan ndikim të rëndësishëm në rritjen e prodhimit.
2. Korrelacioni midis Variablave: • Matrica e korrelacionit tregoi një lidhje të fortë pozitive midis plehrave kimike dhe prodhimit të drithërave ($r = 0.89$), si dhe midis CO₂ dhe prodhimit të drithërave ($r = 0.75$). • Plehurat kimike rezultuan faktori kryesor që ndikon në prodhimin e drithërave.
3. Stacionariteti dhe Përgatitja e Modeleve: • Seria kohore për prodhimin e drithërave ishte jo-stacionare dhe u transformua përmes diferencimit për t'u bërë e përshtatshme për modelim. • Modelet u ndërtuan dhe krahasuan për të identifikuar qasjen më të përshtatshme për parashikime.
4. Modelet e Zbatuara: • Modeli i Regresit Linear tregoi ndikim të qartë të plehrave kimike në prodhimin e drithërave, me një $R^2 = 0.79$. • Modelet ARIMA, ETS, Holt-Winters dhe TBATS u përdorën për parashikime afatshkurtra dhe afatgjata. • Modeli TBATS tregoi performancë të mirë për shkak të fleksibilitetit të tij në trajtimin e trendit dhe sezonalityt.
5. Performanca e Modeleve: • TBATS rezultoi më i saktë për dataset-in aktual me një gabim relativisht të ulët (MAPE = 4.04%). • Modelet si ETS dhe Holt shfaqën gabime më të larta krahasuar me TBATS dhe ARIMA.
6. Rezultatet Kryesore të Parashikimit: • Parashikimet treguan se prodhiimi i drithërave do të vazhdojë të rritet, por rritja është e ndikuar ndjeshëm nga përdorimi i plehrave kimike. • Në rast të uljes së përdorimit të plehrave kimike ose emetimeve të CO₂, prodhiimi mund të ketë ulje të konsiderueshme.
7. Vlerësimi i Gabimeve dhe Mbetjeve: • Analiza e mbetjeve tregoi që shumica e modeleve nuk kanë autokorrelacion të mbetjeve, duke treguar përshtatje të mirë me të dhënat. • Megjithatë, disa shpërndarje të mbetjeve devijuan nga normaliteti, duke sugjeruar nevojën për përmirësime në trajtimin e të dhënave ose përzgjedhjen e modeleve.

Detyra tregoi se modelet TBATS dhe ARIMA janë të përshtatshme për parashikimin e prodhimit të drithërave në bazë të serive kohore. Përmirësimi i vazhdueshëm i metodave dhe analizave mund të ndihmojë në marrjen e parashikimeve më të sakta për të ndihmuar politikatat bujqësore dhe menaxhimin mjedisor.

8. Referencat

- “Laboratore për Seritë Kohore” - Arnisa Sokoli
- “Time Series Analysis and Its Applications: With R Examples” - Shumway & Stoffer
- “Forecasting: Principles and Practice” - Hyndman & Athanasopoulos